

Quiz 2 复习冲刺讲义

Classification 分类算法全考点梳理

最推荐的使用方式

第一遍，只读蓝框”结论与直觉”和橙框”核心流程”；第二遍，结合绿框”例题”把详细机制读懂。

目录

1 分类基础概念	2
2 二分类与多分类	2
3 过拟合 (Overfitting)	3
4 混淆矩阵 (Confusion Matrix)	3
5 特征缩放 (Feature Scaling)	4
6 常见分类算法	4
6.1 支持向量机 (SVM)	4
6.2 逻辑回归 (Logistic Regression)	5
6.3 朴素贝叶斯 (Naïve Bayes)	5
6.4 神经网络分类器	6
6.5 深度学习的优势	6
7 评估指标 (Evaluation Metrics)	6
8 ROC 曲线	7
9 决策边界 (Decision Boundary)	8
10 处理不平衡数据集	8
11 算法辨析速查表	9

1 分类基础概念

分类的核心目标

在机器学习中，分类（Classification）的目的是将输入数据分配到预定义的类别标签中。这与回归（预测连续数值）和聚类（无预定义标签的分组）有本质区别。

分类 vs 回归 vs 聚类 — 快速辨析

- 分类（Classification）：有预定义标签，输出是离散类别（如：垃圾邮件/正常邮件）
- 回归（Regression）：预测连续数值（如：房价预测）
- 聚类（Clustering）：无预定义标签，自动分组（如：K-Means）

例题：分类问题识别

Q: 以下哪个是分类问题？

- a. 估算房屋价格 b. 判断邮件是否为垃圾邮件 c. 计算平方根 d. 预测明天温度

A: b. 判断邮件是否为垃圾邮件是典型的二分类问题。

2 二分类与多分类

二分类与多分类

二分类（Binary Classification）只有两个可能的类别（如：是/否）。

多分类（Multi-class Classification）涉及两个以上的类别（如：猫/狗/鸟）。

例题：二分类的类别数

Q: 二分类中有多少个可能的类别？

- a. 一个 b. 三个 c. 两个 d. 无限

A: c. 二分类的定义就是只有两个类别。

例题：多分类定义

Q: 涉及超过两个类别的分类问题是什么类型？

- a. 多分类（Multi-class） b. 回归 c. 二分类 d. 聚类

A: a. 超过两个类别就是多分类。

3 过拟合 (Overfitting)

过拟合的本质

过拟合是指模型学习了训练数据中的噪声和特定模式，导致泛化能力下降。模型在训练集上表现很好，但在测试集上表现差。

过拟合的特征

- 训练误差很低，测试误差很高
- 模型过于复杂（参数过多）
- 训练数据不足或噪声过多

直觉：就像学生死记硬背了练习题的答案，但考试换了数字就不会了。

例题：过拟合的定义

Q: 过拟合意味着什么？

a. 特征太少 b. 训练和测试表现都好 c. 未能捕获模式 d. 学习了训练数据的噪声

A: d. 过拟合 = 学习了训练数据的噪声和特定模式，泛化能力差。

4 混淆矩阵 (Confusion Matrix)

混淆矩阵的作用

混淆矩阵用于评估分类模型的性能，展示预测结果与真实标签的对比关系。

混淆矩阵四象限

	预测 = 正	预测 = 负
实际 = 正	TP (真正例)	FN (假负例)
实际 = 负	FP (假正例)	TN (真负例)

- TP (True Positive): 正确分类的正例
- FP (False Positive): 负例被错误分类为正例 (“虚报”)
- FN (False Negative): 正例被错误分类为负例 (“漏报”)
- TN (True Negative): 正确分类的负例

例题：False Positive 的含义

Q: 混淆矩阵中 FP 代表什么？

- a. 正确分类的正例 b. 负例被错误分为正例 c. 正确分类的负例 d. 正例被错误分为负例

A: b。FP = 负例被错误分类为正例。

例题：混淆矩阵的作用

Q: 混淆矩阵的作用是？

- a. 可视化训练数据分布 b. 降维 c. 衡量回归误差 d. 评估分类模型性能

A: d。混淆矩阵是分类模型的性能评估工具。

5 特征缩放 (Feature Scaling)

为什么需要特征缩放

特征缩放确保所有特征对分类过程的贡献均等。如果特征的量纲差异很大（如年龄 0-100 vs 收入 0-1000000），未缩放时大数值特征会主导模型。

常见缩放方法

- 标准化 (Standardization): $z = \frac{x - \mu}{\sigma}$, 均值 0, 标准差 1
- 归一化 (Normalization): $x' = \frac{x - x_{min}}{x_{max} - x_{min}}$, 缩放到 [0, 1]

例题：特征缩放的目的是

Q: 特征缩放的主要目的是？

- a. 提高可解释性 b. 确保特征贡献均等 c. 减少特征数 d. 增加训练样本

A: b。确保所有特征在分类过程中贡献均等。

6 常见分类算法

6.1 支持向量机 (SVM)

SVM 核心思想

SVM 通过寻找最大间隔超平面来分隔不同类别的数据。适用于中小规模数据集且类别之间有清晰边界的情况。

例题：SVM 适用场景

Q: SVM 最适合什么场景？

a. 中小数据集且类别边界清晰 b. 非线性回归 c. 聚类 d. 缺失值数据

A: a。SVM 在中小规模、有清晰类别边界的数据上表现最好。

6.2 逻辑回归 (Logistic Regression)

逻辑回归的核心目的

逻辑回归的主要目的是估计二元结果的概率。它使用 Sigmoid 函数将线性回归的输出映射到 $[0, 1]$ 区间。

逻辑回归的 Sigmoid 函数

$$P(y = 1|x) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

其中 $z = w^T x + b$ 。

当 $P \geq 0.5$ 时预测为正类，否则预测为负类。

例题：逻辑回归的目的

Q: 逻辑回归的主要目的是？

a. 估计二元结果的概率 b. 预测连续值 c. 聚类 d. 降维

A: a。逻辑回归本质上是概率估计模型。

6.3 朴素贝叶斯 (Naïve Bayes)

Naïve Bayes 的理论基础

朴素贝叶斯基于贝叶斯定理 (Bayes' Theorem)，假设各特征之间条件独立。

$$P(y|x_1, \dots, x_n) \propto P(y) \prod_{i=1}^n P(x_i|y)$$

例题：基于贝叶斯定理的算法

Q: 以下哪个算法基于贝叶斯定理？

a. KNN b. 决策树 c. 朴素贝叶斯 d. 随机森林

A: c。Naïve Bayes 直接基于贝叶斯定理。

6.4 神经网络分类器

激活函数的作用

在神经网络分类器中，**激活函数**的核心作用是引入非线性。没有激活函数，多层网络等价于单层线性变换，无法学习复杂模式。

常见激活函数

- **Sigmoid**: $\sigma(x) = \frac{1}{1+e^{-x}}$ ，输出 $[0, 1]$ ，常用于二分类输出层
- **ReLU**: $f(x) = \max(0, x)$ ，最常用的隐藏层激活
- **Softmax**: 多分类输出层，将输出转为概率分布

例题：激活函数的作用

Q: 激活函数在神经网络中的主要作用是？

- a. 引入非线性 b. 标准化输入 c. 确定学习率 d. 减少过拟合

A: a。引入非线性是激活函数最核心的作用。

6.5 深度学习的优势

深度学习的关键优势

深度学习模型的关键优势是能从原始数据中自动提取特征，无需手动特征工程。

例题：深度学习优势

Q: 深度学习的一个关键优势是？

- a. 总是可解释的 b. 需要更少数据 c. 计算成本低 d. 自动提取特征

A: d。深度学习能自动从原始数据中提取特征。

7 评估指标 (Evaluation Metrics)

核心评估指标

- **Accuracy** (准确率): $\frac{TP+TN}{TP+TN+FP+FN}$ ，正确预测的比例
- **Precision** (精确率): $\frac{TP}{TP+FP}$ ，预测为正的中有多少是真的正
- **Recall** (召回率): $\frac{TP}{TP+FN}$ ，所有正例中有多少被找到
- **F1-score**: $\frac{2 \times Precision \times Recall}{Precision + Recall}$ ，精确率和召回率的调和平均

指标选择指南

- 数据均衡 → 用 Accuracy
- 数据不均衡 → 用 F1-score (Accuracy 会失效)
- 关注虚报 (如垃圾邮件过滤) → 关注 Precision
- 关注漏报 (如疾病检测) → 关注 Recall

例题：综合指标

Q: 哪个指标同时考虑了精确率和召回率？

- a. R-squared b. Accuracy c. MAE d. F1-score

A: d. F1-score 是精确率和召回率的调和平均。

例题：Accuracy 的缺陷

Q: 使用 Accuracy 的主要缺点是？

- a. 计算昂贵 b. 不均衡数据集表现差 c. 需要大数据集 d. 需要特征缩放

A: b. 在不均衡数据集上，Accuracy 会产生误导 (如 99% 样本为负类时，全预测负就有 99% 准确率但毫无意义)。

例题：非分类指标

Q: 以下哪个指标通常不用在分类问题中？

- a. Precision b. Accuracy c. MSE d. F1-score

A: c. MSE (均方误差) 是回归指标，不用于分类。

8 ROC 曲线

ROC 曲线的含义

ROC 曲线 (Receiver Operating Characteristic) 展示了真正率 (TPR) 与假正率 (FPR) 之间的权衡关系。

其中 $TPR = Recall = \frac{TP}{TP+FN}$, $FPR = \frac{FP}{FP+TN}$ 。

ROC 曲线解读

- 曲线越靠近左上角，模型越好
- AUC (曲线下面积) 越接近 1 越好
- 对角线 (AUC=0.5) = 随机猜测

例题：ROC 曲线展示的内容

Q: ROC 曲线展示了什么？

a. 特征重要性 b. 精确率与召回率的关系 c. TPR 与 FPR 的权衡 d. 回归误差

A: c。ROC 展示的是真正率（TPR）和假正率（FPR）的权衡。

9 决策边界 (Decision Boundary)

决策边界的作用

决策边界用于在特征空间中分隔不同类别。它是模型做出分类决策的“分界线”。

例题：决策边界

Q: 决策边界的用途是？

a. 数据降维 b. 预测数值 c. 分隔不同类别 d. 确定缺失值

A: c。决策边界在特征空间中分隔不同类别。

10 处理不平衡数据集

不平衡数据集的挑战

当正负样本比例严重失衡时（如 1:100），多数类会主导模型训练，少数类容易被忽略。

处理不平衡数据的方法

- 过采样（Oversampling）少数类：如 SMOTE 算法
- 欠采样（Undersampling）多数类
- 调整类别权重（class weights）
- 使用 F1-score 而非 Accuracy 评估

例题：处理不平衡数据

Q: 如何处理不平衡数据集？

a. 降低学习率 b. 过采样少数类 c. 减少训练轮数 d. 增加特征数

A: b。过采样少数类是处理不平衡数据的经典方法。

11 算法辨析速查表

常用分类算法速查

算法	核心原理	适用场景
逻辑回归	Sigmoid + 线性组合	简单二分类，可解释性要求高
SVM	最大间隔超平面	中小数据集，清晰边界
朴素贝叶斯	贝叶斯定理 + 条件独立	文本分类，小样本
决策树	信息增益/基尼系数分裂	可解释性要求高
随机森林	多棵决策树集成	几乎所有场景
神经网络	多层非线性变换	大数据，复杂模式
深度学习	自动特征提取 + 端到端学习	图像、语音、NLP